Распознавание действий и событий

от метки на клипе — к «что, когда и нормально ли» в длинном видео

Александр Савельев

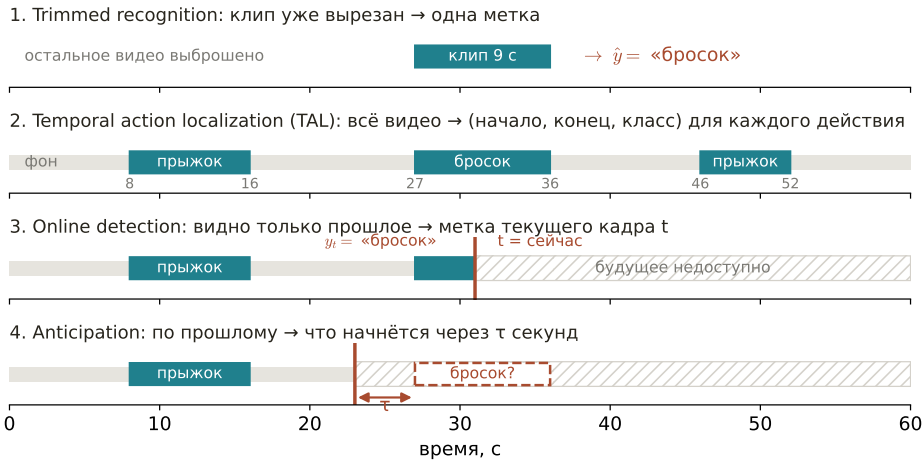
Курс: Обработка видео в контексте машинного обучения и ИИ
Лекция 4

Сюжет лекции, не оглавление

В лекции 3 модель получала *вырезанный* клип и отвечала одной меткой. Сегодня одна нить на все слайды: *каждая новая постановка отнимает у модели одно знание о времени*.

1. Четыре постановки: что модель знает о времени, а что — нет
2. Метрика: когда предсказанный отрезок считается «найденным» (tIoU, AP, mAP)
3. Дубли и NMS: почему без них метрика проваливается
4. TAL: от скользящих окон и proposals — к «каждый момент сам предсказывает действие»
5. Длинное видео и онлайн: память и причинная маска
6. Аномалии: нет классов, нет границ — есть только «нормально / нет»
7. Эгоцентрика

1. Одно видео — четыре разных вопроса о времени



Сверху вниз модель знает о времени всё меньше: границы → будущее → даже настоящее (anticipation).

1. Формально: trimmed recognition и TAL

Trimmed recognition (задача лекции 3)

$$\hat{y} = \arg\max_{c \in \{1,\dots,C\}} p_\theta\big(c \mid X_{1:T}\big)$$

$X_{1:T}$ — клип из T кадров, *внутри ровно одно действие*; C — число классов (Kinetics-400: $C = 400$); p_θ — вероятность класса по модели с весами θ.

Temporal Action Localization, TAL

$$\hat{\mathcal{S}} = \big\{(s_k,\, e_k,\, c_k,\, q_k)\big\}_{k=1}^{K}, \qquad 0 \le s_k < e_k \le T$$

Для *необрезанного* видео вернуть K отрезков: начало s_k, конец e_k, класс c_k, уверенность $q_k \in [0, 1]$. K заранее неизвестно, отрезки могут перекрываться.

Главное отличие: в TAL *границы* — часть ответа, а не часть входа.

1. Формально: online detection и anticipation

Online action detection

$$p_\theta\big(y_t \mid X_{1:t}\big), \qquad y_t \in \{0, 1, \ldots, C\}$$

Метка *текущего* кадра t по кадрам $1..t$ — будущего нет. $y_t = 0$ — «фон», ничего не происходит.

Action anticipation

$$p_\theta\big(y_{t+\tau} \mid X_{1:t}\big)$$

Что будет через горизонт τ: EPIC-Kitchens — $\tau = 1$ с; Ego4D LTA — последовательность из 20 будущих действий.

Online — это не «TAL с обрезкой». Модель не видит конца действия, поэтому обязана решать по началу. Реальные системы (наблюдение, спорт, liveness в KYC) почти всегда онлайн.

1. Датасеты: масштаб и что именно размечено

Датасет	Объём	Классы	Разметка	Метрика
THUMOS14	413 видео (200 val / 213 test), ∼6.3 тыс. действий	20, спорт	границы + класс; действие ∼4 с, ∼15 на видео	mAP@{0.3..0.7}
ActivityNet 1.3	19 994 видео, 648 ч	200, быт	границы + класс; ∼1.5 длинных действия на видео	mAP@{0.5..0.95}
EPIC-Kitchens-100	700 видео, 100 ч, 20 млн кадров	97 глаголов × 300 сущ.	90 тыс. сегментов, вид от первого лица	mAP@{0.1..0.5}
Ego4D	3 670 ч, 931 человек, 74 локации	—	нарративы, episodic memory, руки и объекты, прогноз	свой у каждой задачи
UCF-Crime	1 900 видео, 128 ч	13 аномалий	train: метка *видео*; test: покадрово	frame-level AUC

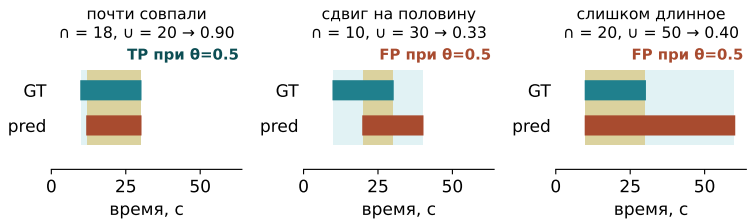
Исторический казус THUMOS14: обучаются на *val*, тестируют на *test*. ActivityNet проще по границам (одно длинное действие), но сложнее по классам.

2. tIoU: насколько два отрезка времени совпали

Temporal IoU

$$\mathrm{tIoU}(g,p) = \frac{|g \cap p|}{|g \cup p|} = \frac{\max\big(0,\ \min(e_g,e_p) - \max(s_g,s_p)\big)}{\max(e_g,e_p) - \min(s_g,s_p)}$$

$g = (s_g, e_g)$ — истинный отрезок (ground truth), $p = (s_p, e_p)$ — предсказанный. Числитель — длина пересечения, знаменатель — длина объединения (охвата).



золотое — пересечение ∩, голубое — объединение ∪

2. Что на самом деле означает порог $\theta = 0.5$

Пусть предсказание той же длины L, что и GT, но сдвинуто на δ ($0 \le \delta \le L$):

$$|g \cap p| = L - \delta, \qquad |g \cup p| = L + \delta \quad \Rightarrow \quad \text{tIoU} = \frac{L - \delta}{L + \delta}.$$

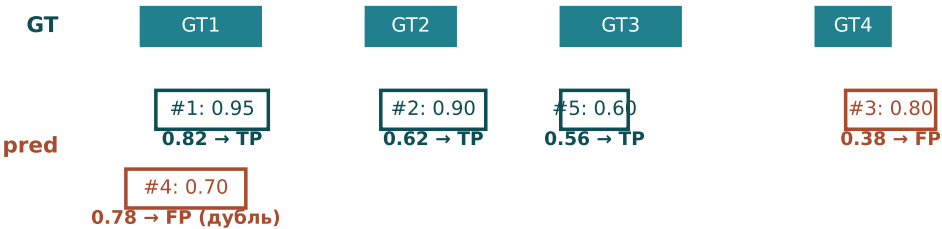
Условие tIoU $\ge \theta$ решаем относительно δ:

$$\delta \;\le\; L \cdot \frac{1 - \theta}{1 + \theta}.$$

θ	допустимый сдвиг	при $L = 4$ с (THUMOS14)	смысл
0.3	$0.54L$	2.2 с	«нашли, что где-то тут»
0.5	$L/3$	1.3 с	границы примерно верны
0.7	$0.18L$	0.7 с	границы точные

Низкие пороги меряют «нашли ли», высокие — «насколько точны границы». Короткие действия при $\theta = 0.7$ требуют точности до долей секунды.

2. Сопоставление: какое предсказание «нашло» какой GT



1. Все предсказания класса сортируем по уверенности q — от большей к меньшей.
2. Для очередного ищем *свободный* GT с максимальным tIoU. Если tIoU $\geq \theta$ — это TP, GT помечаем занятым; иначе FP.
3. Каждый GT засчитывается *один раз*: второе попадание в тот же GT — FP.

На рисунке ($\theta = 0.5$): #4 перекрывает GT1 на 0.78, но GT1 уже занят #1 $\Rightarrow$ FP; #3 задел GT4 слабо (0.38) $\Rightarrow$ FP, GT4 не найден $\Rightarrow$ recall < 1.

2. Precision и recall после каждого предсказания

После первых k предсказаний (по убыванию q):

$$P_k = \frac{\mathrm{TP}_k}{\mathrm{TP}_k + \mathrm{FP}_k} = \frac{\mathrm{TP}_k}{k}, \qquad R_k = \frac{\mathrm{TP}_k}{N_{\mathrm{gt}}}.$$

$\mathrm{TP}_k, \mathrm{FP}_k$ — накопленные числа верных и ложных; $N_{\mathrm{gt}} = 4$ — сколько всего истинных действий класса.

k	q	tIoU	вердикт	TP_k	FP_k	P_k	R_k
1	0.95	0.82	TP	1	0	1.00	0.25
2	0.90	0.62	TP	2	0	1.00	0.50
3	0.80	0.38	FP	2	1	0.67	0.50
4	0.70	0.78	FP, дубль	2	2	0.50	0.50
5	0.60	0.56	TP	3	2	0.60	0.75

Recall растёт только на TP. Precision может и падать, и снова расти (строка 5).

2. AP — площадь под «причёсанной» кривой precision–recall

Average Precision класса c

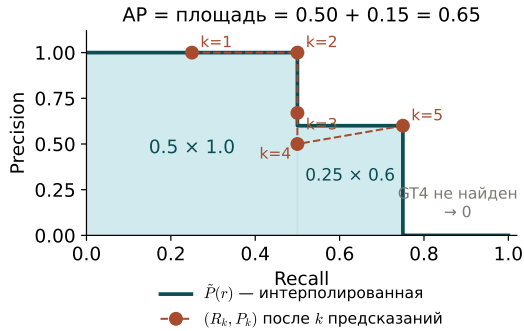
$$\tilde{P}(r) = \max_{\rho \geq r} P(\rho)$$

$$\mathrm{AP}_c(\theta) = \sum_k \left(R_k - R_{k-1}\right) \tilde{P}(R_k)$$

$\tilde{P}(r)$ — интерполированная precision: лучшая точность, достижимая при recall *не меньше* r. Убирает «пилу».

Сумма — площадь прямоугольников: ширина — прирост recall, высота — $\tilde{P}$.

Наш пример:
$0.25 \cdot 1 + 0.25 \cdot 1 + 0.25 \cdot 0.6 = \mathbf{0.65}$.



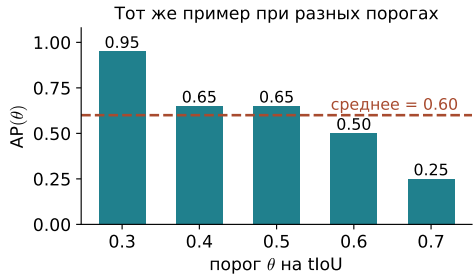
2. mAP: усредняем по классам, потом по порогам

$$\text{mAP@}\theta = \frac{1}{C}\sum_{c=1}^{C} \text{AP}_c(\theta)$$

$$\overline{\text{mAP}} = \frac{1}{|\Theta|}\sum_{\theta\in\Theta} \text{mAP@}\theta$$

C — число классов; Θ — набор порогов: THUMOS14 $\{0.3, 0.4, \ldots, 0.7\}$, ActivityNet $\{0.5, 0.55, \ldots, 0.95\}$. $\overline{\text{mAP}}$ («average mAP») — главное число в таблицах статей.

Справа — AP того же примера при пяти порогах. При $\theta = 0.3$ №3 (tIoU 0.38) становится TP и находит GT4 $\Rightarrow$ AP = 0.95.



2. Листинг: AP одного класса при пороге θ

Алгоритм: AP@θ

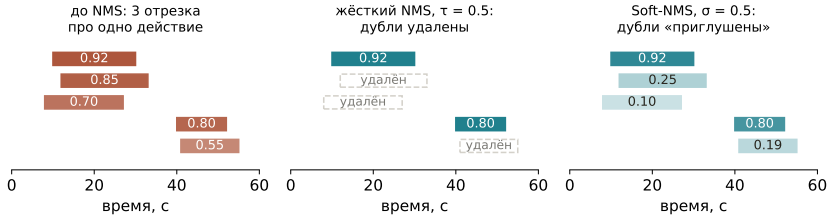
вход: предсказания $\{(s_i, e_i, q_i)\}$ класса c; GT $\{(s_j, e_j)\}$, N_{gt} штук; порог θ
выход: $\text{AP}_c(\theta)$

1. отсортировать предсказания по q_i по убыванию; все GT пометить свободными
2. **для** каждого предсказания i по порядку:
   2.1 $j^* = \arg\max_{j \text{ свободен}} \text{tIoU}(g_j, p_i)$
   2.2 если $\text{tIoU} \geq \theta$: TP, g_{j^*} занят; иначе FP
3. накопленные суммы $\Rightarrow P_k = \text{TP}_k/k$, $R_k = \text{TP}_k/N_{\text{gt}}$
4. $\tilde{P}_k = \max_{k' \geq k} P_{k'}$ — проход справа налево
5. $\text{AP} = \sum_k (R_k - R_{k-1})\, \tilde{P}_k$, $R_0 = 0$

Ненайденные GT в сумму не попадают — recall просто не дорастает до 1, и площадь обрезается.

3. Дубли убивают precision — нужен NMS

Модель обычно выдаёт несколько похожих отрезков на одно действие. По правилу «один GT — одно TP» все, кроме первого, становятся FP.



Жёсткий NMS и Soft-NMS

Берём лучший отрезок M. Для остальных b_i: жёсткий: $q_i \leftarrow 0$, если $\mathrm{tIoU}(M, b_i) > \tau$; Soft-NMS: $q_i \leftarrow q_i \cdot \exp\!\left(-\mathrm{tIoU}(M, b_i)^2 / \sigma\right)$.

τ — порог перекрытия, σ — ширина гауссова «гашения» (≈ 0.5). Чем сильнее перекрытие с лучшим, тем сильнее падает уверенность.

3. Листинг: Soft-NMS по времени

Алгоритм: Soft-NMS

вход: отрезки $\{(s_i, e_i, q_i)\}$ одного класса; σ; минимальный score $q_{\min}$; максимум K
выход: не более K отрезков с пересчитанными q

1. $\mathcal{R} \leftarrow \varnothing$ (результат), $\mathcal{B} \leftarrow$ все отрезки
2. **пока** $\mathcal{B} \neq \varnothing$ и $|\mathcal{R}| < K$:
   - 2.1 $M \leftarrow \arg\max_{b \in \mathcal{B}} q_b$; перенести M из $\mathcal{B}$ в $\mathcal{R}$
   - 2.2 **для** каждого $b_i \in \mathcal{B}$: $q_i \leftarrow q_i \, e^{-\mathrm{tIoU}(M, b_i)^2 / \sigma}$
   - 2.3 выбросить из $\mathcal{B}$ всё, где $q_i < q_{\min}$

Почему не жёсткий: два *разных* действия подряд (два прыжка) перекрываются у границы. Жёсткий NMS удалит второе, Soft-NMS только понизит его уверенность — оно останется в ранжировании. ActionFormer: $q_{\min} = 0.001$, $K = 200$ на видео.

4. Типовой конвейер TAL



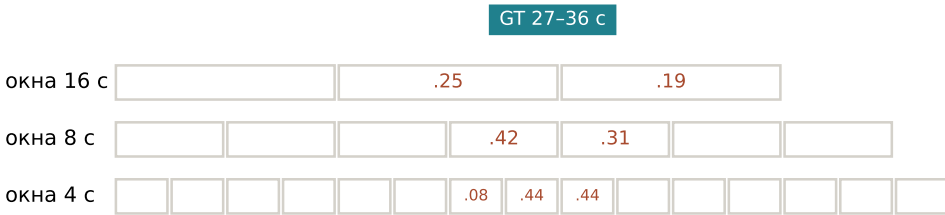
Клиповые признаки

$$X = \left[\, \varphi(\text{клип}_1),\ \varphi(\text{клип}_2),\ \ldots,\ \varphi(\text{клип}_T) \,\right] \in \mathbb{R}^{T \times D}$$

φ — видеобэкбон из лекции 3 (I3D, VideoMAE), обычно *заморожен*; клип — 16 кадров, следующий начинается через 4 кадра (stride). T — число клипов (THUMOS14: $T \approx 2304$), D — размер признака (I3D: 2048).

Дальше всё видео — это матрица $T \times D$, и TAL-голова учится за минуты на одной GPU.

4. Наивная идея: скользящие окна + классификатор

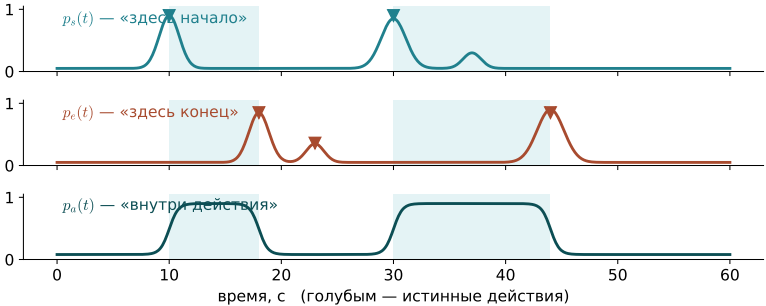


Числа в окнах — tIoU с GT (пустые = 0). Лучшее — 0.44: ни одно окно не прошло $\theta = 0.5$.

- Окна фиксированной длины не совпадают с границами действия: точность границ $\approx$ шаг сетки.
- Длины действий от 1 до 100+ с $\Rightarrow$ нужно много длин $\times$ много сдвигов = тысячи окон.

Вывод: границы надо *предсказывать*, а не перебирать. Дальше — три способа это сделать.

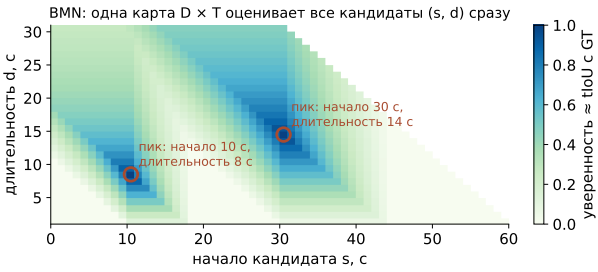
4. BSN: границы как вероятности



Boundary-Sensitive Network (2018) для каждого момента t выдаёт три числа: $p_s(t)$ — «здесь начало», $p_e(t)$ — «здесь конец», $p_a(t)$ — «внутри действия».

1. пики p_s и пики p_e (треугольники) — кандидаты в границы;
2. каждая пара «начало раньше конца» — кандидат-отрезок (proposal);
3. уверенность proposal $\approx p_s(s) \cdot p_e(e) \cdot$ среднее p_a внутри; ложный пик конца в 23 с отсеется.

4. BMN: одна карта оценивает *все* кандидаты сразу



Boundary-Matching Network (2019) вместо перебора пар пиков строит карту $M \in \mathbb{R}^{D \times T}$:

$$M[d, s] \approx \max_{g} \text{tIoU}\big((s, s{+}d),\, g\big).$$

s — начало кандидата, d — длительность, D — максимальная длительность; цель обучения — tIoU кандидата с ближайшим GT.

Пики карты (кружки) — лучшие proposals. Класс им присваивает *отдельный* классификатор.

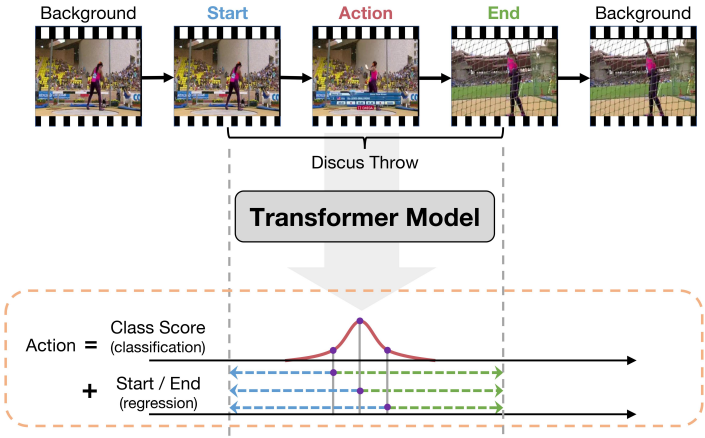
4. Почему от proposals ушли

- **Две стадии**: proposals и классификация учатся раздельно — ошибка первой не исправляется второй.
- **Эвристики**: пороги выбора пиков, плотная карта $D \times T$ — тысячи кандидатов на видео.
- **Числа**: THUMOS14 mAP@0.5 — BSN 36.9, BMN 38.8 против 71.0 у ActionFormer. Оговорка: у BSN/BMN признаки TSN, у ActionFormer — I3D, сравнение не вполне честное.

Аналогия с детекцией объектов: BSN/BMN — это «RPN + классификатор» (Faster R-CNN), следующий метод — «каждая точка сама предсказывает рамку» (FCOS), только в 1D.

Идея «граница — это вероятность» не умерла: вернётся в TriDet.

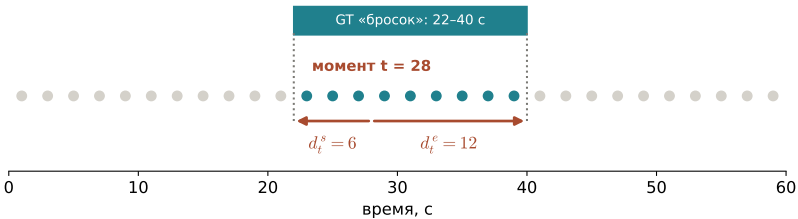
4. ActionFormer: каждый момент сам предсказывает действие



Источник: Zhang, Wu, Li — ActionFormer, ECCV 2022; рисунок из `github.com/happyharrycn/actionformer_release`

Anchor-free: нет ни окон, ни proposals. Для каждого момента t — класс и два расстояния до границ.

4. Anchor-free: момент t предсказывает расстояния до границ

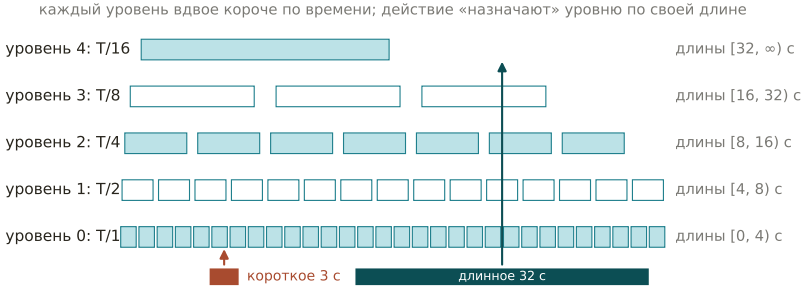


Регрессия границ

$$\left(d_t^s,\ d_t^e\right) = \mathrm{ReLU}\big(\mathrm{Conv1d}(z_t)\big), \qquad \hat{s}_t = t - d_t^s, \quad \hat{e}_t = t + d_t^e$$

z_t — признак момента t после временной модели; $d_t^s, d_t^e \geq 0$ — сколько секунд (клипов) до начала и до конца. ReLU гарантирует неотрицательность. Параллельно вторая голова даёт $p_t(c)$ — вероятность каждого класса в момент t.

4. Пирамида: короткие действия — снизу, длинные — сверху



- Уровень ℓ получается из $\ell-1$ даунсэмплингом $\times 2$: $T_\ell = T/2^\ell$. В оригинале 6 уровней.
- Каждому уровню — свой диапазон длин. Действие 3 с учит уровень 0, действие 32 с — уровень 4.
- Головы классификации и регрессии *общие* для всех уровней — как FPN в детекции.

4. Кто из моментов — положительный пример

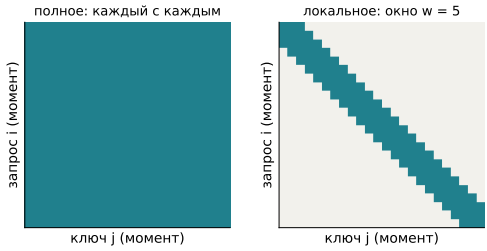
Момент t уровня ℓ учится на действие $g = (s, e, c)$, только если выполнены три условия:

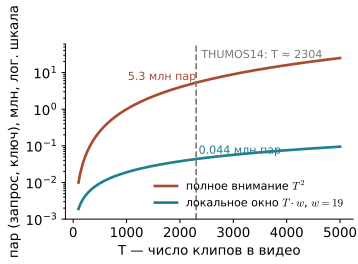
$$\underbrace{s \le t \le e}_{\text{внутри}} \;\wedge\; \underbrace{\left| t - \tfrac{s+e}{2} \right| \le r \cdot 2^{\ell}}_{\text{около центра}} \;\wedge\; \underbrace{\max(d^{s}, d^{e}) \in [a_{\ell},\, b_{\ell})}_{\text{длина «своего» уровня}}$$

2^{ℓ} — шаг уровня в клипах; $r \approx 1.5$ — радиус центр-сэмплинга; $[a_{\ell}, b_{\ell})$ — диапазон расстояний уровня (справа на рисунке пирамиды).

- Остальные моменты — фон: у них учится только классификация (цель «ни одного класса»).
- Около края действия признак уже наполовину «фон» — такие точки дают шумную регрессию, поэтому их и отсекает условие центра.
- Фона в десятки раз больше, чем положительных $\Rightarrow$ обычная кросс-энтропия утонет в лёгких примерах. Отсюда focal loss.

4. Временная модель: локальное внимание вместо полного





полное: $\mathcal{O}(T^2 D)$ локальное: $\mathcal{O}(T\,w\,D), \quad w = 19$

T — число клипов, D — размер признака, w — окно внимания (каждый момент видит ± 9 соседей). При $T = 2304$: 5.3 млн пар против 44 тыс. — в 120 раз дешевле. Дальний контекст даёт пирамида: на уровне 5 окно 19 покрывает $19 \cdot 32$ клипов.

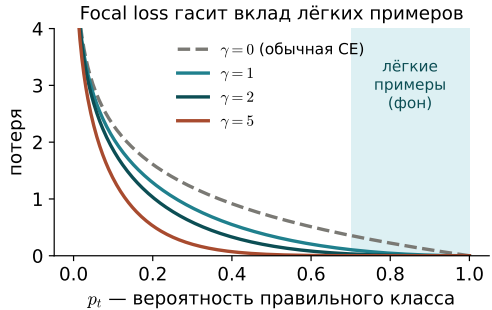
4. Лосс, часть 1: focal loss для классов

Focal loss

$$\mathcal{L}_{\text{focal}}(p_t) = -(1-p_t)^{\gamma}\,\log p_t$$

p_t — вероятность, которую модель дала *правильному* ответу (для фона — «нет класса»); $\gamma \geq 0$ — сила фокусировки, обычно $\gamma = 2$; при $\gamma = 0$ — обычная кросс-энтропия.

Пример: лёгкий фон с $p_t = 0.9$.
CE: $-\log 0.9 = 0.105$.
Focal: $0.1^2 \cdot 0.105 = 0.001$ — в 100 раз меньше.
Трудный пример $p_t = 0.1$: вес $0.9^2 = 0.81$ — почти не тронут.

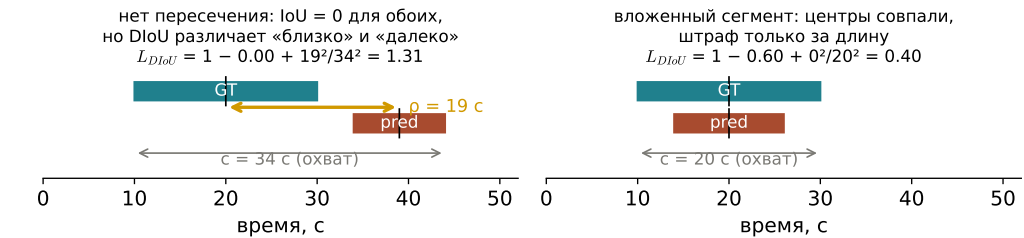


4. Лосс, часть 2: DIoU для границ

Distance-IoU loss

$$\mathcal{L}_{\text{DIoU}}(\hat{\psi}, \psi) = 1 - \text{tIoU}(\hat{\psi}, \psi) + \frac{\rho^2}{c^2}$$

$\psi = (s, e)$ — GT, $\hat{\psi}$ — предсказание; ρ — расстояние между их центрами; c — длина общего охвата. Второе слагаемое тянет центры друг к другу, даже когда пересечения нет.



Почему не L1 по (d^s, d^e): ошибка 1 с для действия 2 с и для 60 с весит одинаково. tIoU масштабно-инвариантна.

4. Полный лосс ActionFormer

$$\mathcal{L} = \frac{1}{T_+} \sum_{\ell} \sum_{t} \Big[\mathcal{L}_{\text{focal}}\big(p_t,\, c_t\big) \;+\; \mathbf{1}\big[c_t \neq \varnothing\big]\, \mathcal{L}_{\text{DIoU}}\big(\hat{\psi}_t,\, \psi_t\big) \Big]$$

Символ	Что это
$\ell,\ t$	уровень пирамиды и момент на нём — суммируем по *всем* точкам всех уровней
c_t	целевой класс момента; $\varnothing$ — фон
p_t	предсказанные вероятности классов в момент t
$\mathbf{1}[c_t \neq \varnothing]$	индикатор: 1, если момент положительный, иначе 0 — границы учатся только внутри действий
$\hat{\psi}_t,\ \psi_t$	предсказанный $(\hat{s}_t, \hat{e}_t)$ и истинный отрезок
T_+	число положительных моментов — нормировка, чтобы длинные видео не доминировали

4. Листинг: обучение ActionFormer

Алгоритм: ActionFormer, один шаг обучения

вход: признаки $X \in \mathbb{R}^{T \times D}$; GT $\{(s_k, e_k, c_k)\}$; уровни $L = 6$; окно $w = 19$
выход: обновлённые веса

1. $Z_0 \leftarrow$ Conv1d-проекция X в D' каналов
2. **для** $\ell = 1..L-1$: $Z_\ell \leftarrow$ Transformer-блок с локальным вниманием w, затем даунсэмплинг $\times 2$
3. **для** каждого уровня ℓ и момента t: $p_t \leftarrow \sigma(\text{Conv1d}_{\text{cls}}(z_t))$, $(d_t^s, d_t^e) \leftarrow \text{ReLU}(\text{Conv1d}_{\text{reg}}(z_t)) \cdot 2^\ell$
4. назначить цели: c_t и ψ_t по трём условиям (внутри, около центра, длина уровня)
5. $\mathcal{L} = \frac{1}{T_+} \sum [\mathcal{L}_{\text{focal}} + \mathbf{1}[c_t \neq \varnothing] \mathcal{L}_{\text{DIoU}}]$; шаг AdamW

Умножение на 2^ℓ переводит расстояния из шагов уровня в клипы исходной оси — головы общие, а масштаб у каждого уровня свой.

4. Листинг: инференс ActionFormer

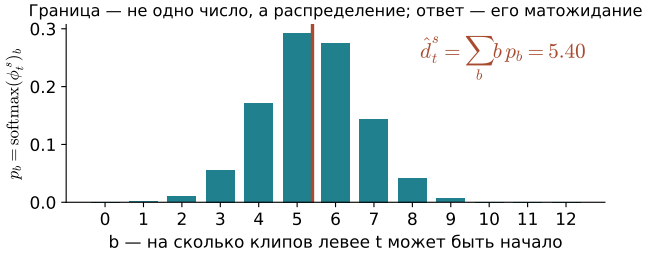
Алгоритм: ActionFormer, предсказание на одном видео

вход: признаки X; порог $q_{\min} = 0.001$; $K = 200$
выход: список (s, e, c, q)

1. прогнать сеть $\Rightarrow$ для каждой точки всех уровней $p_t(c)$ и $(\hat{s}_t, \hat{e}_t)$
2. кандидаты: все пары (точка, класс) с $p_t(c) > q_{\min}$; отрезок $(\hat{s}_t, \hat{e}_t)$, $q = p_t(c)$
3. перевести клипы в секунды: $t_{\text{сек}} = (t \cdot \text{stride} + \frac{16}{2})/\text{fps}$
4. Soft-NMS отдельно по каждому классу; оставить K лучших

Результат на THUMOS14 с I3D-признаками: mAP 82.1 / 71.0 / 43.9 при tIoU 0.3 / 0.5 / 0.7, среднее 66.8. Резкое падение к 0.7 — это и есть «размытые границы», с которыми борются следующие методы.

4. TriDet: граница — распределение, а не точка



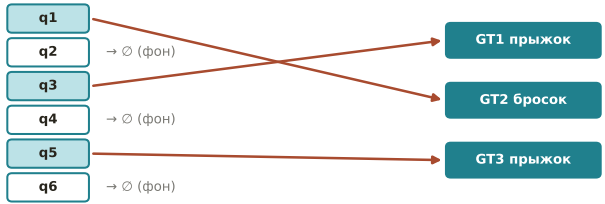
Trident-head (CVPR 2023)

$$\hat{d}_t^s = \sum_{b=0}^{B} b \cdot \mathrm{softmax}\left(\phi_t^s\right)_b$$

$\phi_t^s \in \mathbb{R}^{B+1}$ — логиты «начало на b клипов левее t»; B — максимальное расстояние; ответ — матожидание, т.е. дробное число. Три ветви: начало, конец и центр. Плюс SGP-слой вместо self-attention — дешевле.

THUMOS14, I3D: average mAP 69.3 против 66.8 у ActionFormer.

4. TadTR: DETR для времени — без NMS

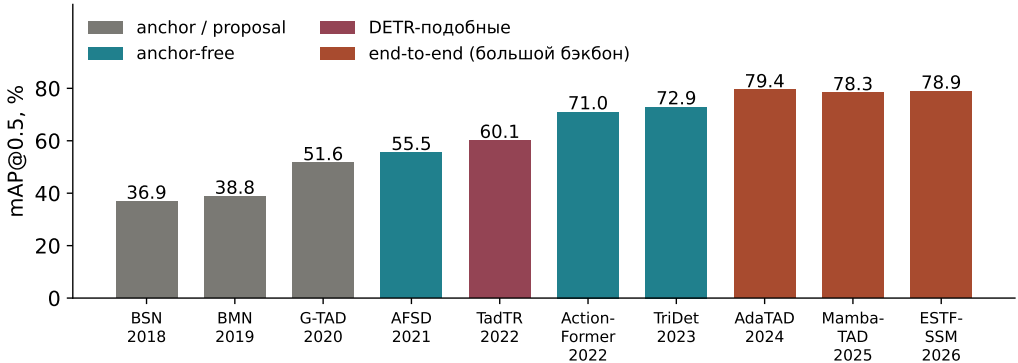


каждому GT — ровно один запрос; лишние учатся отвечать ∅ → NMS не нужен

$$\hat{\sigma} = \arg\min_{\sigma} \sum_{i=1}^{N_{\text{gt}}} C_{i,\sigma(i)}, \qquad C_{ij} = -\hat{p}_j(c_i) + \lambda \left\| \psi_i - \hat{\psi}_j \right\|_1 + \mu\big(1 - \text{tIoU}(\psi_i, \hat{\psi}_j)\big)$$

N обучаемых запросов $q_1..q_N$ выдают N отрезков. σ — сопоставление «GT $i \to$ запрос $\sigma(i)$» (венгерский алгоритм); C_{ij} — цена пары «GT i — запрос j»: $-$вероятность нужного класса, L1 и tIoU-расстояние границ; λ, μ — веса (5 и 2). Несопоставленные запросы учатся отвечать $\varnothing$. Минус: мало данных (200 видео) — медленная сходимость; THUMOS14: 56.7.

4. THUMOS14: за 8 лет mAP@0.5 выросла с 37 до 79



Два скачка: anchor-free с пирамидой (ActionFormer, $+11$) и end-to-end дообучение огромных бэкбонов (AdaTAD: VideoMAEv2-giant, 1536 кадров, $+6$). Честно: признаки на графике разные, вклад головы и бэкбона смешан. При фиксированных I3D: TadTR 60.1, ActionFormer 71.0, TriDet 72.9.

4. Сводка: четыре семейства TAL

Семейство	Пример	Как получают отрезок	NMS	avg mAP	Плюсы / минусы
proposals	BSN, BMN	пики начала/конца или карта $D \times T \to$ классификатор	да	$\sim$37–48 (TSN)	понятно; две стадии, эвристики
anchor-free	ActionFormer, TriDet	момент $t \to$ класс $+ (d^s, d^e)$	Soft	66.8 / 69.3	просто и сильно; зависит от NMS
DETR	TadTR	N запросов $\to N$ отрезков, matching	нет	56.7	без NMS, легко с текстом; данные
end-to-end	AdaTAD	anchor-free голова + дообучаемый бэкбон	Soft	75.4	лучшие числа; 1 млрд параметров
SSM	MambaTAD, ESTF-SSM	голова на state-space блоках, линейно по T	Soft	74.2 / 75.3	дёшево по длине; молодое

avg mAP — THUMOS14, пороги 0.3–0.7. Первые три строки — замороженные признаки, последние две — end-to-end.

4. 2025–2026: бэкбон важнее головы

- **End-to-end на 1000+ кадрах**: AdaTAD (CVPR 2024) — адаптеры в замороженном VideoMAEv2-giant, 1536 кадров, 75.4 avg mAP.
- **SSM вместо внимания**: MambaTAD (74.2), ESTF-SSM (ICME 2026, 75.3 avg mAP / 78.9 mAP@0.5) — линейная стоимость по T.
- **Масштаб признаков**: тот же ActionFormer на признаках InternVideo2-6B — 71.9 вместо 66.8.
- **Zero-shot и онлайн**: OZ-TAL (2026) — классы задаются текстом, кадры приходят потоком; на THUMOS14 пока $\sim$9 avg mAP — задача далека от решения.
- **EPIC-Kitchens-100**, детекция действий (глагол + существительное), челлендж CVPR 2026: лучший результат $\sim$32 avg mAP.

Инженерный вывод: голова даёт единицы mAP, бэкбон — десятки. Начинать с лучшего бэкбона, который позволяет бюджет.

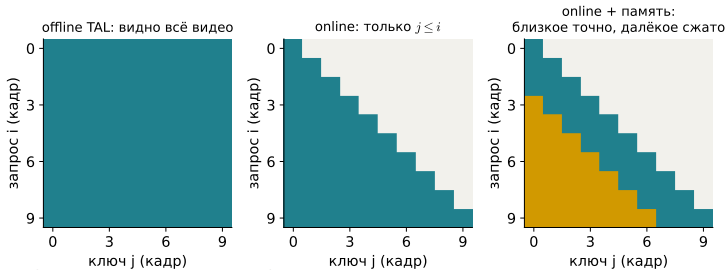
5. Почему длинное видео — отдельная проблема

- Час при 30 fps — $108\,000$ кадров. Даже по клипам (stride 4) это $\sim 27\,000$ токенов.
- Полное внимание по ним: $27\,000^2 \approx 7 \cdot 10^8$ пар на каждый слой.
- Клип в 16–32 кадра не видит контекста: «взял нож» — готовит или угрожает?
- Онлайн добавляет запрет: в момент t нельзя смотреть на $t+1$.

Три ответа, которые разберём

1. **Причинная маска** — одна и та же сеть работает в потоке.
2. **Кэш** ключей и значений прошлого — не пересчитывать старые кадры.
3. **Сжатая память** — далёкое прошлое хранится грубо (MeMViT, LSTR).

5. Причинное внимание — это просто маска



бирюзовый — внимание разрешено; бежевый — запрещено ($M = -\infty$); золотой — через сжатую память

$$A_{ij} = \mathrm{softmax}_j\left(\frac{q_i^\top k_j}{\sqrt{d}} + M_{ij}\right), \qquad M_{ij} = \begin{cases} 0, & j \le i \\ -\infty, & j > i \end{cases}$$

q_i — запрос кадра i, k_j — ключ кадра j, d — размер головы внимания; A_{ij} — сколько кадр i «смотрит» на кадр j. $e^{-\infty} = 0 \Rightarrow$ вес будущих кадров ровно ноль.

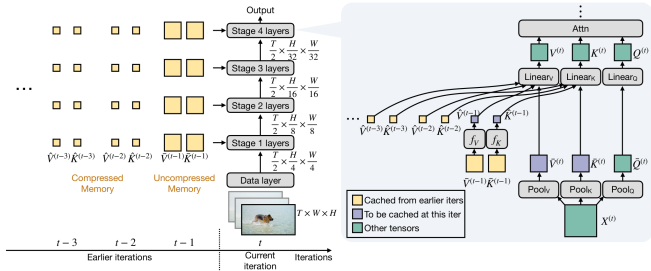
5. Следствие маски: инкрементальный инференс



При причинной маске выход для кадра *t не меняется*, когда приходят новые кадры. Значит:

- K, V старых кадров можно посчитать один раз и хранить — тот же KV-кэш, что в LLM;
- на каждый новый кадр — $\mathcal{O}(t)$ операций вместо $\mathcal{O}(t^2)$;
- но кэш растёт линейно с длиной видео $\Rightarrow$ нужна *сжатая* память.

5. MeMViT: память из сжатых ключей и значений

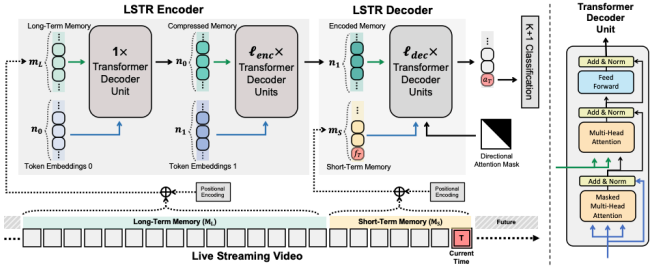


Источник: Wu et al. — MeMViT, CVPR 2022, рис. 2 (arXiv:2201.08383)

$$\tilde{K}^{(t)} = \Big[\, \mathrm{sg}\big(f_K(\tilde{K}^{(t-1)})\big),\ K^{(t)} \Big]$$

$K^{(t)}$ — ключи текущего клипа t; $\tilde{K}^{(t-1)}$ — ключи с памятью с прошлого шага; f_K — обучаемое сжатие (пулинг), sg — stop-gradient: в прошлое градиент не идёт; $[\cdot,\cdot]$ — конкатенация по токенам. Рекурсия $\Rightarrow$ в памяти всё прошлое, всё грубее. Для V так же.

5. LSTR: долгая память сжата, короткая — целиком



Источник: Xu et al. — LSTR, NeurIPS 2021; рисунок из `github.com/amazon-science/long-short-term-transformer`

$$\text{стоимость} = \mathcal{O}\big(L_s^2 + L_s \cdot m\big), \qquad m \ll L_l$$

L_s — короткая память (последние 8 с, все кадры); L_l — долгая (до 512 с); m — число токенов после сжатия долгой памяти (16–32). Стоимость не зависит от L_l.

5. Онлайн-детекция: как меряют и что получилось

Метрика другая, чем в TAL: **per-frame mAP** — AP по *кадрам* для каждого класса. Каждый кадр — «предсказание» со score $p_t(c)$; TP, если кадр действительно класса c. Числа с TAL-mAP несравнимы.

Метод	Год	per-frame mAP	Идея
LSTR	2021	69.5	долгая + короткая память
TeSTra	2022	71.2	кэш с экспоненциальным забыванием
MAT	2023	71.6	память + предсказание будущего
CMeRT	2025	73.2	контекст + уточнение памяти

Anticipation на THUMOS14 (avg mAP по горизонтам): LSTR 52.6 $\rightarrow$ CMeRT 59.5.

Источник: CMeRT, arXiv:2503.18359, табл. 2 и 3

6. Аномалии: нет классов, нет границ

Задача: для каждого кадра t выдать $s_t \in [0, 1]$ — насколько он «ненормален». Аномалии редки и разнообразны: перечислить их классами нельзя.

Модель нормы (без аномалий)

Учим автоэнкодер или предсказатель кадра *только* на нормальном видео. Аномальность = ошибка модели.

$+$ примеры аномалий не нужны
$-$ хороший AE восстановит и аномалию

UCSD Ped2, CUHK Avenue, ShanghaiTech

Weakly-supervised MIL

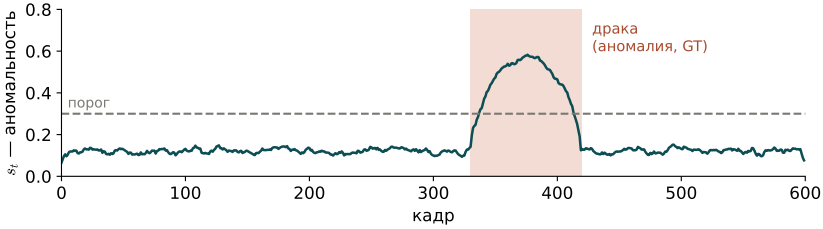
Есть аномальные и нормальные видео, но *где* аномалия — неизвестно. Метка только на всё видео.

$+$ учится на реальных аномалиях
$-$ шумная цель: «где-то внутри»

UCF-Crime (13 типов, 128 ч), XD-Violence

Полная покадровая разметка аномалий почти не встречается: дорого и редко.

6. Модель нормы: аномальность — это ошибка восстановления



Reconstruction-based

$$s_t = \left\| x_t - D_\phi\left(E_\phi(x_t)\right) \right\|_2^2$$

x_t — кадр (или клип, или его признак); E_ϕ — энкодер, сжимающий x_t в узкий код; D_ϕ — декодер, восстанавливающий x_t из кода; ϕ — их веса, обученные только на норме. Норму модель видела — восстанавливает хорошо; драку не видела — ошибка большая.

6. Предсказание будущего кадра: аномалия — нарушение динамики

Liu et al. (CVPR 2018): U-Net по кадрам $t{-}4..t{-}1$ предсказывает $\hat{x}_t$. Обучение — только на норме; лосс — яркость + градиенты + оптический поток + GAN.

$$\mathrm{PSNR}_t = 10 \log_{10} \frac{\left(\max \hat{x}_t\right)^2}{\mathrm{MSE}(x_t, \hat{x}_t)}$$

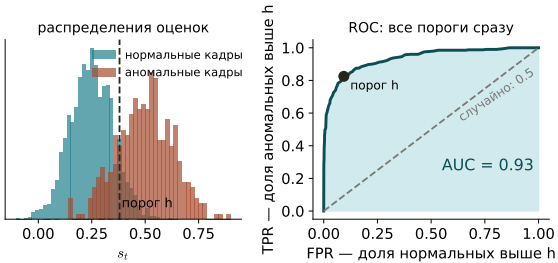
PSNR — отношение пикового сигнала к шуму в децибелах; MSE — средний квадрат ошибки по пикселям. Высокий PSNR — кадр предсказуем (норма), низкий — нет.

$$s_t = 1 - \frac{\mathrm{PSNR}_t - \min_{t'} \mathrm{PSNR}_{t'}}{\max_{t'} \mathrm{PSNR}_{t'} - \min_{t'} \mathrm{PSNR}_{t'}}$$

Min-max нормировка *внутри одного видео* переводит PSNR в $s_t \in [0, 1]$; единица — худший кадр видео.

Почему предсказание лучше реконструкции: аномалия — чаще нарушение *движения*, а не внешнего вида. Чтобы предсказать кадр, модель обязана выучить нормальную динамику.

6. Метрика: frame-level ROC-AUC



s_t — оценка аномальности кадра, h — порог: кадр с $s_t \geq h$ объявляем аномальным.

$$\mathrm{TPR}(h) = \frac{\#\{\text{аном.: } s_t \geq h\}}{\#\text{аном.}}$$

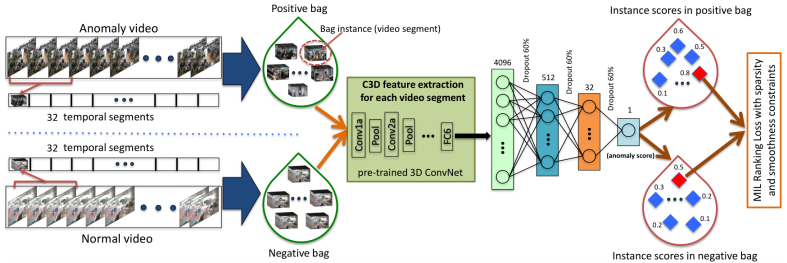
$$\mathrm{FPR}(h) = \frac{\#\{\text{норм.: } s_t \geq h\}}{\#\text{норм.}}$$

TPR — доля пойманных аномальных кадров, FPR — доля ложных тревог.

$$\mathrm{AUC} = \int_0^1 \mathrm{TPR}\, d\,\mathrm{FPR} = \Pr\left(s_{\text{аном}} > s_{\text{норм}}\right)$$

ROC — кривая $(\mathrm{FPR}(h), \mathrm{TPR}(h))$ при всех h; AUC — площадь под ней, она же вероятность, что случайный аномальный кадр оценён выше случайного нормального. 0.5 — монетка, 1.0 — идеально. Порог выбирать не нужно, но и границы аномалии AUC не меряет.

6. UCF-Crime: видео — сумка сегментов



Источник: Sultani, Chen, Shah — Real-world Anomaly Detection in Surveillance Videos, CVPR 2018, рис. 1

- Каждое видео режут на $n = 32$ сегмента; признак сегмента — C3D (позже I3D, CLIP).
- Аномальное видео — *положительная сумка*: хотя бы один сегмент аномален. Нормальное — *отрицательная*: все сегменты нормальны.
- Общий MLP $512 \to 32 \to 1$ с сигмоидой даёт оценку $f(V^i) \in [0, 1]$ каждому сегменту.

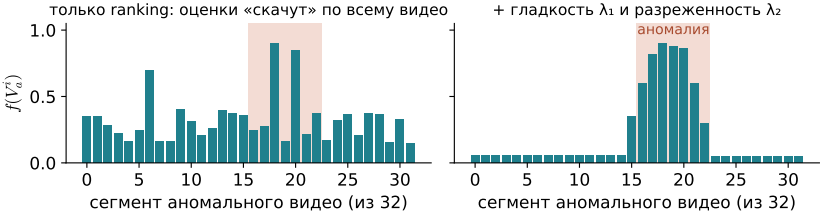
6. MIL-ranking: раздвинуть максимумы двух сумок



$$\ell(\mathcal{B}_a, \mathcal{B}_n) = \max\Big(0,\ 1 - \max_{i \in \mathcal{B}_a} f(V_a^i) + \max_{i \in \mathcal{B}_n} f(V_n^i)\Big)$$

$\mathcal{B}_a, \mathcal{B}_n$ — сумки сегментов аномального и нормального видео; V^i — признак сегмента i; f — оценка сегмента. Почему *максимумы*: самый подозрительный сегмент аномального видео должен быть выше самого подозрительного нормального хотя бы на 1 (зазор, margin). Иначе — штраф (hinge).

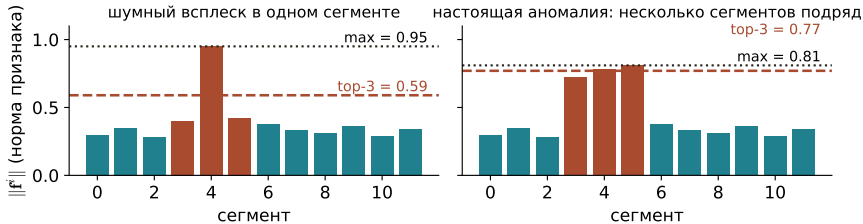
6. Гладкость и разреженность



$$\mathcal{L} = \ell(\mathcal{B}_a, \mathcal{B}_n) + \lambda_1 \underbrace{\sum_{i=1}^{n-1} \left(f(V_a^i) - f(V_a^{i+1})\right)^2}_{\text{гладкость}} + \lambda_2 \underbrace{\sum_{i=1}^{n} f(V_a^i)}_{\text{разреженность}}$$

Гладкость: соседние сегменты похожи — оценки не должны прыгать. Разреженность: аномалия занимает малую часть видео — сумма оценок мала. В статье $\lambda_1 = \lambda_2 = 8 \cdot 10^{-5}$, $n = 32$. Обе штрафуют только аномальную сумку: у нормальной оценки и так прижаты к нулю через ranking.

6. RTFM: не один максимум, а среднее top-k



$$\ell_{\text{RTFM}} = \max\bigl(0,\ m - \bar{g}_k(\mathcal{B}_a) + \bar{g}_k(\mathcal{B}_n)\bigr), \qquad \bar{g}_k(\mathcal{B}) = \frac{1}{k} \sum_{i \in \text{top}_k(\mathcal{B})} \bigl\|\mathbf{f}^i\bigr\|_2$$

$\mathbf{f}^i$ — признак сегмента i, $\|\cdot\|_2$ — его длина (норма); top_k — $k = 3$ сегмента с наибольшей нормой; m — зазор. Один шумный всплеск (слева) почти не сдвигает среднее, а настоящая аномалия из нескольких сегментов (справа) — сдвигает. UCF-Crime: 84.3 AUC против 75.4 у исходного MIL.

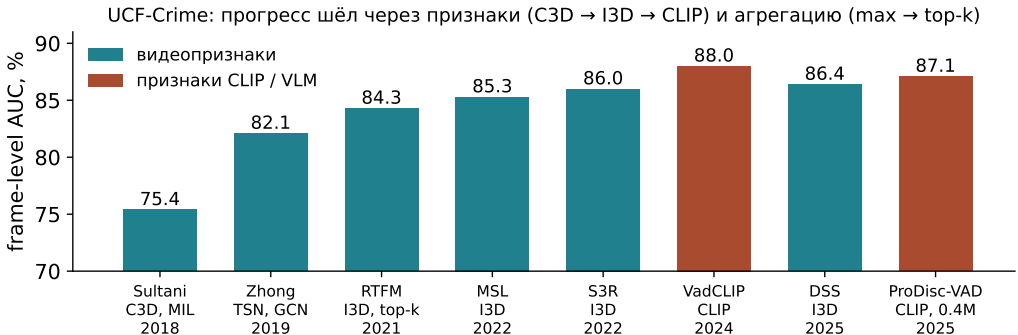
6. Листинг: обучение MIL на UCF-Crime

Алгоритм: MIL-ranking (Sultani et al.)

вход: признаки сегментов: аномальные видео $\{V_a\}$, нормальные $\{V_n\}$, по $n = 32$ на видео; λ_1, λ_2
выход: MLP f, оценка сегмента

1. каждое видео $\to$ 32 равных по времени сегмента; признак сегмента — среднее клиповых признаков внутри
2. **повторять**: батч из B аномальных и B нормальных видео (пары)
   - 2.1 $f_a \leftarrow f(V_a) \in [0,1]^{B\times 32}$, $f_n \leftarrow f(V_n)$
   - 2.2 ranking: $\max(0,\ 1 - \max f_a + \max f_n)$ по каждой паре
   - 2.3 $+\lambda_1$·гладкость f_a $+\lambda_2$·сумма f_a; шаг оптимизатора
3. тест: оценку сегмента раздать всем его кадрам $\Rightarrow s_t$; frame-level AUC по всему тесту

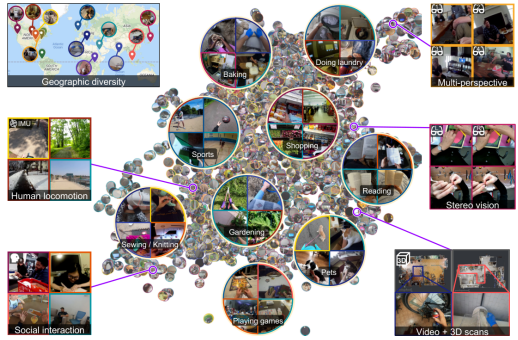
6. UCF-Crime: 75 → 88 AUC за семь лет



Рост шёл через *признаки* (C3D → I3D → CLIP) и *агрегацию* (max → top-*k*). ProDisc-VAD: 87.1 при голове в 0.4 млн параметров — упираемся в признаки, не в размер модели. Оговорка: AUC считается по всем кадрам теста, где норма — подавляющее большинство; короткие аномалии локализуются всё ещё плохо.

7. Эгоцентрическое видео меняет и данные, и постановки

- Камера на голове: сильное собственное движение, руки и объекты крупно — признаки Kinetics переносятся плохо.
- EPIC-Kitchens-100: действие = глагол + существительное (97 $\times$ 300); детекция, anticipation ($\tau = 1$ с).
- Ego4D: 3 670 ч, 931 человек; episodic memory, руки и объекты, прогноз 20 действий (метрика — edit distance).
- Вывод: нужен бэкбон, предобученный на эгоцентрике (EgoVLP, Ego4D-VideoMAE).



Источник: Grauman et al. — Ego4D, CVPR 2022, рис. 1

Итог — та же нить

1. Постановки различаются тем, что модель знает о времени: trimmed $\rightarrow$ TAL $\rightarrow$ online $\rightarrow$ anticipation
2. tIoU $\geq \theta$ + «один GT — одно TP» $\Rightarrow$ AP как площадь, mAP по классам и порогам; $\theta = 0.5$ — сдвиг $\leq L/3$
3. Дубли — FP, поэтому Soft-NMS обязателен
4. TAL: окна $\rightarrow$ proposals (BSN, BMN) $\rightarrow$ anchor-free (ActionFormer: класс + (d^s, d^e), пирамида, focal + DIoU) $\rightarrow$ распределения границ (TriDet) и запросы без NMS (TadTR)
5. 2024–2026: главный рычаг — бэкбон и end-to-end; SSM дают линейную стоимость по длине
6. Онлайн = причинная маска + KV-кэш + сжатая память (MeMViT, LSTR)
7. Аномалии: ошибка модели нормы или MIL по меткам видео; top-k устойчивее одного максимума

Литература

- **Zhang, Wu, Li** — ActionFormer, ECCV 2022. arxiv.org/abs/2202.07925
- **Lin et al.** — BSN, ECCV 2018; BMN, ICCV 2019
- **Shi et al.** — TriDet, CVPR 2023. github.com/dingfengshi/TriDet
- **Liu et al.** — TadTR, IEEE TIP 2022. arxiv.org/abs/2106.10271
- **Liu et al.** — AdaTAD, CVPR 2024. arxiv.org/abs/2311.17241; тулбокс OpenTAD
- **ESTF-SSM**, ICME 2026. arxiv.org/abs/2604.09164
- **Wu et al.** — MeMViT, CVPR 2022. arxiv.org/abs/2201.08383
- **Xu et al.** — LSTR, NeurIPS 2021; CMeRT, 2025. arxiv.org/abs/2503.18359
- **Liu et al.** — Future Frame Prediction for Anomaly Detection, CVPR 2018
- **Sultani, Chen, Shah** — UCF-Crime, CVPR 2018. arxiv.org/abs/1801.04264
- **Tian et al.** — RTFM, ICCV 2021. arxiv.org/abs/2101.10030
- **Grauman et al.** — Ego4D, CVPR 2022. arxiv.org/abs/2110.07058